

**XXIX Encontro de
Iniciação Científica**

**XIV Encontro de
Iniciação em
Desenvolvimento
Tecnológico e
Inovação 2024**



PUC
CAMPINAS

Nome: Amanda Soares da Silveira

RA: 21018595

Curso: Engenharia de Computação

Bolsa: FAPIC/Reitoria

Orientador: Prof.º Dr. Ademar Takeo Akabane

ARQUITETURA DE REDES NEURAIS PROFUNDAS - VGG

aplicada no diagnóstico de lesão de pele

PROBLEMA PRINCIPAL




importância do Diagnóstico precoce

A detecção rápida de lesões de pele pode salvar vidas, especialmente no caso de melanoma.



Desafio Clínico

Dermatologistas têm dificuldade em diferenciar lesões apenas visualmente.



Solução com IA

Modelos de inteligência artificial auxiliam na classificação de lesões, oferecendo suporte ao diagnóstico.

BANCO DE DADOS


O HAM10000 ("Human Against Machine with 10000 training images") é um dataset público amplamente utilizado para a classificação de lesões de pele

Contém 10.000 imagens de diferentes tipos de lesões de pele, incluindo melanomas, ceratoses e nevos benignos.


HAM 10000



(1) Actinic keratosis




(2) Basal cell carcinoma




(3) Benign keratosis-like lesions



(4) Dermatofibroma



(5) Melanoma

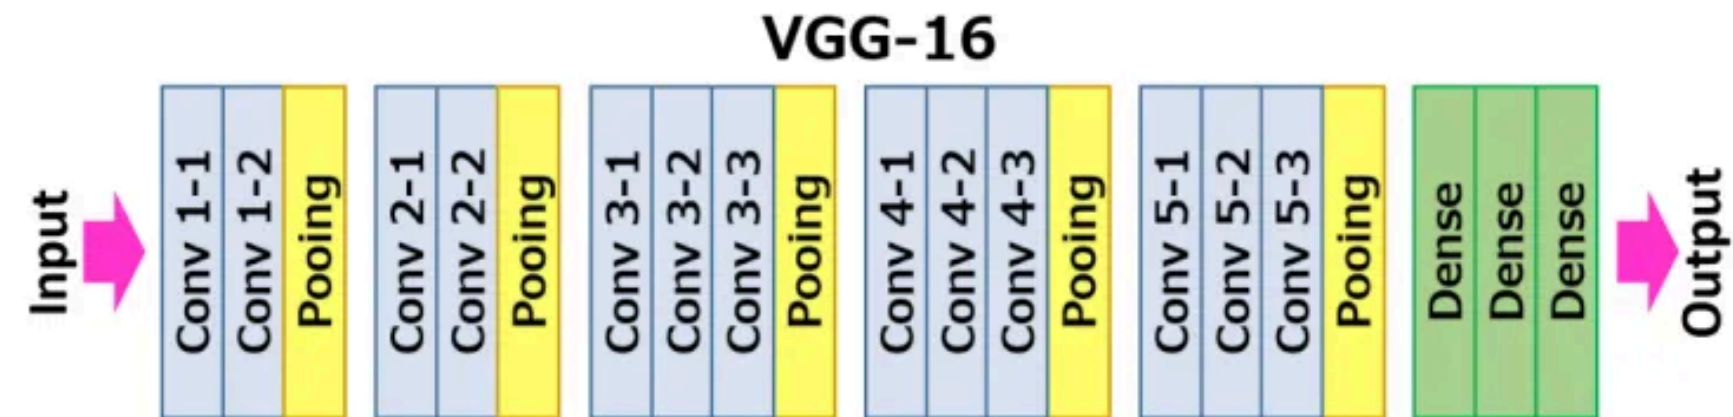


(6) Melanocytic nevi




(7) Vascular lesions

ARQUITETURA VGG



The Architecture

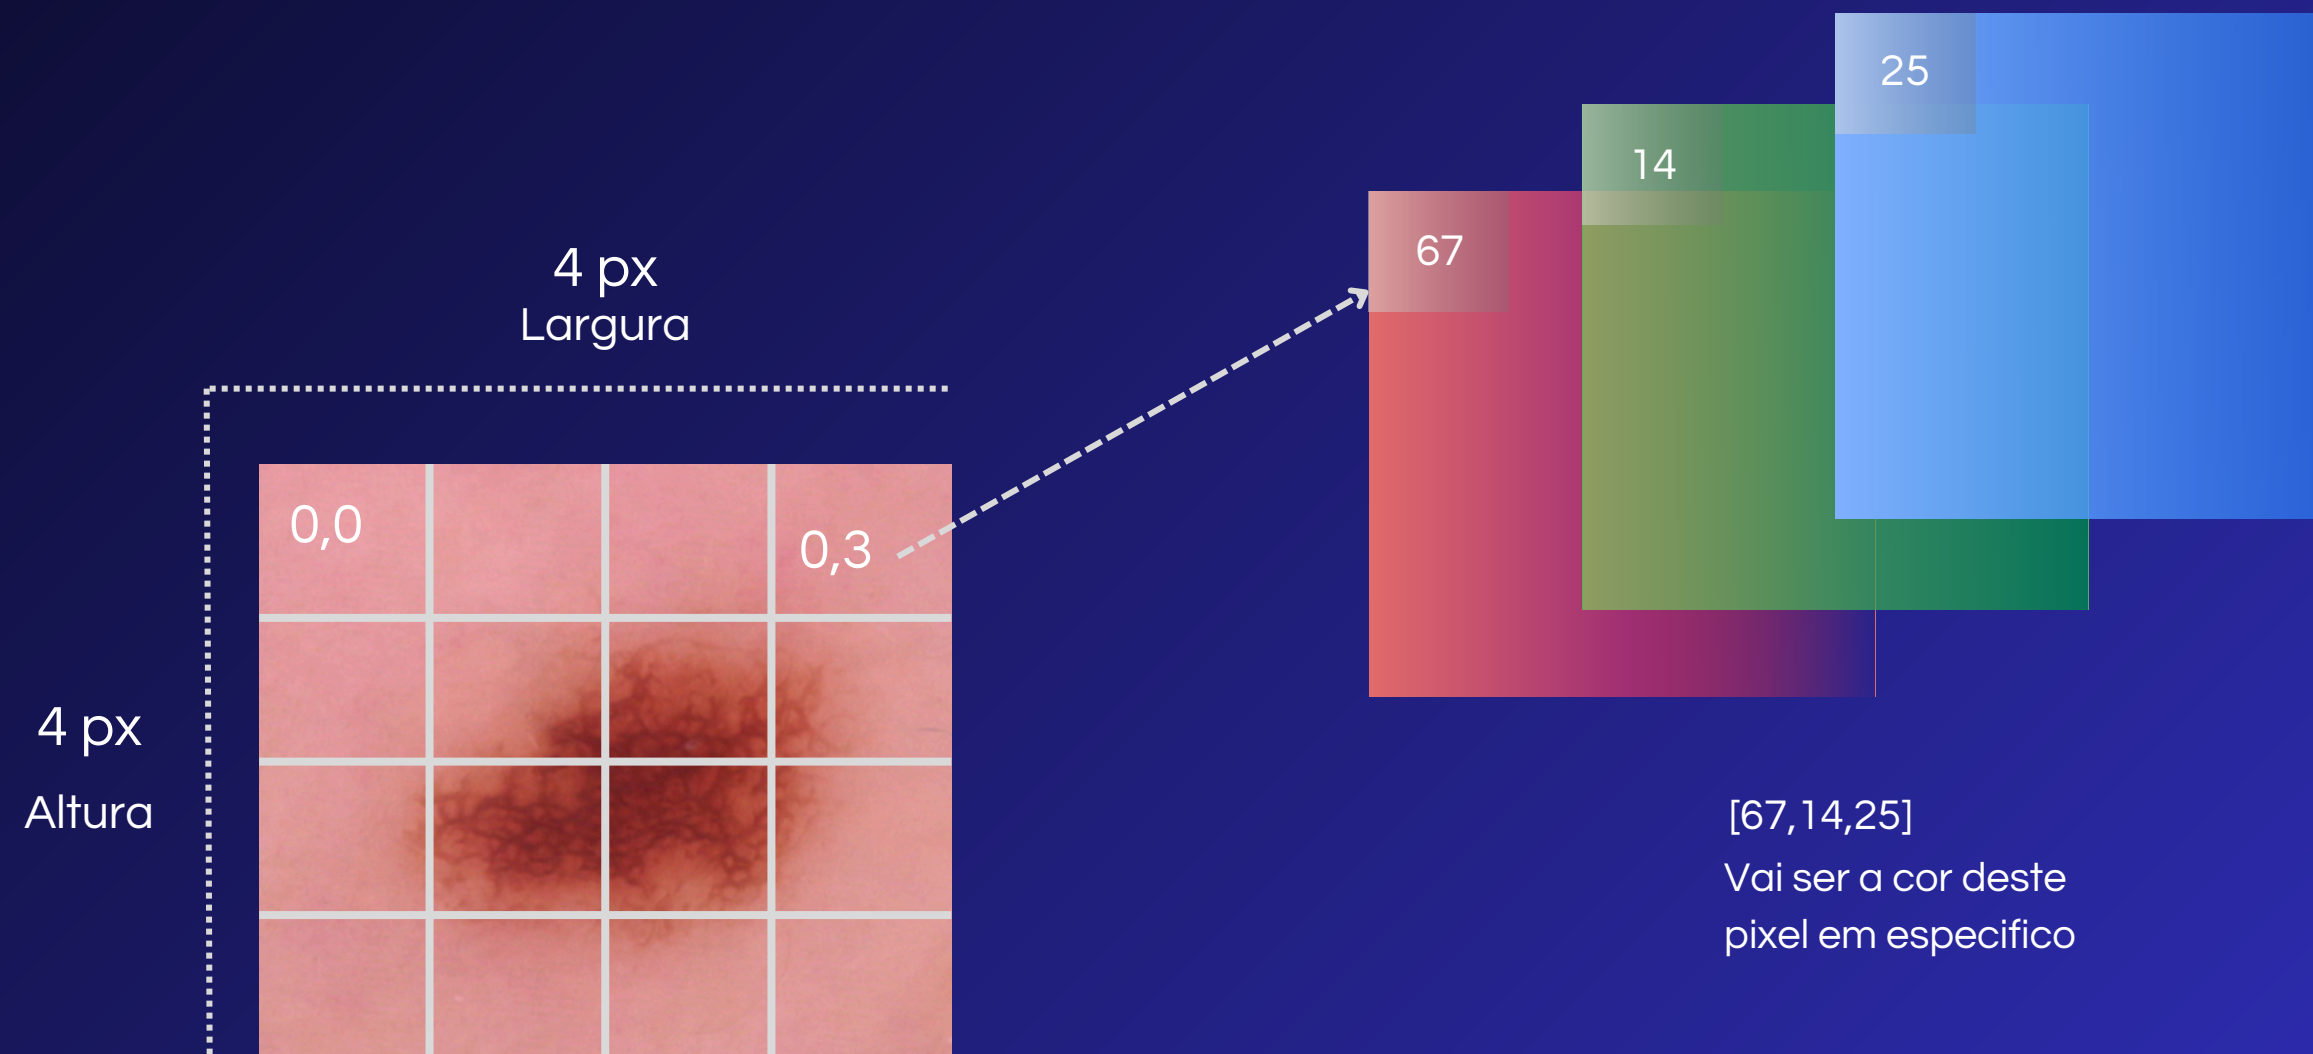
The architecture depicted below is VGG16.



ARQUITETURA VGG

Imagens para computadores


Para um computador, imagens são apenas conjuntos de números que representam cores. Esses números formam uma grande "tabela" de pixels.



ARQUITETURA VGG


Camadas convolucionais

A camada convolucional funciona como um "filtro" que passa por essa tabela de números (imagem), identificando padrões simples, como bordas ou cores. Ela ajuda o modelo a aprender o que é importante numa imagem



ARQUITETURA VGG

Camadas convolucionais



ARQUITETURA VGG

Camada Pooling

O pooling é como um resumo. Ele pega partes da imagem processada e simplifica, mantendo as informações principais, mas reduzindo o tamanho. Isso ajuda a focar nas partes mais importantes da imagem.

0	1	2
3	4	5
6	7	8

2 x 2 Max
Pooling


4	5
7	8

ARQUITETURA VGG

Camada totalmente conectada

Essa camada funciona como um tomador de decisões.

Depois que todos os padrões são analisados, ela usa esses dados para classificar o que está na imagem (por exemplo, se é uma lesão benigna ou um melanoma).




No caso deste problema, a camada de saída deve conter 7 neurônios.

PROCESSO DE TREINAMENTO

Problemas de custo


A arquitetura suporta entradas com tamanho 224×224 . O que é custoso para treinamento

Por conta da ferramenta utilizada, retiramos a ultima camada com uma abordagem mais leve.



PROCESSO DE TREINAMENTO

Durante a análise do dataset, foi identificado um desequilíbrio significativo entre as classes de lesões.



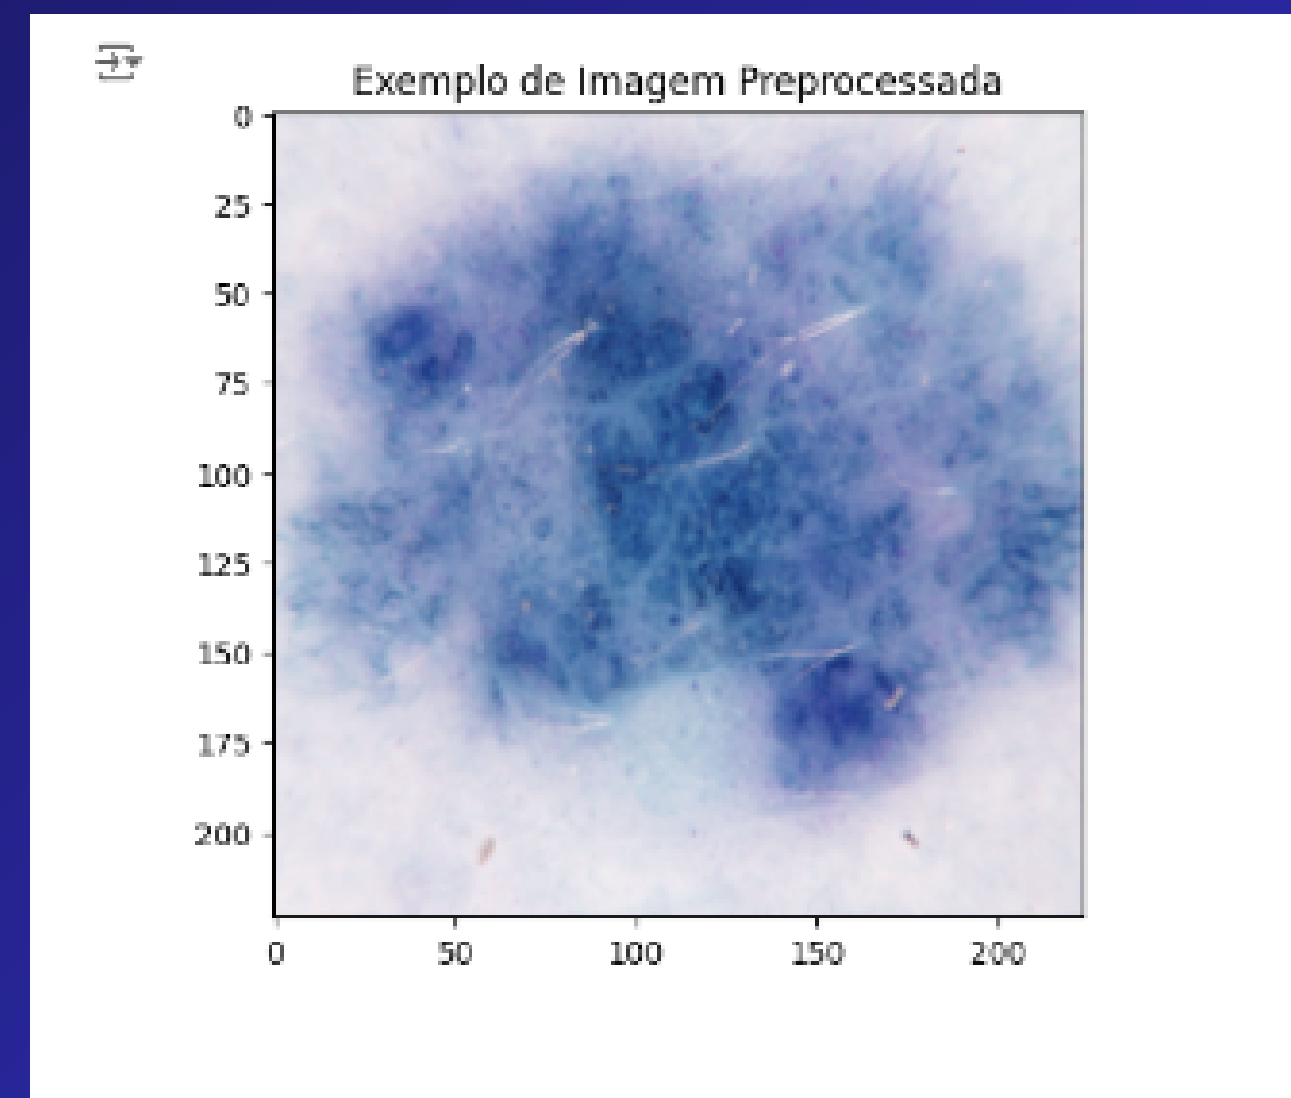
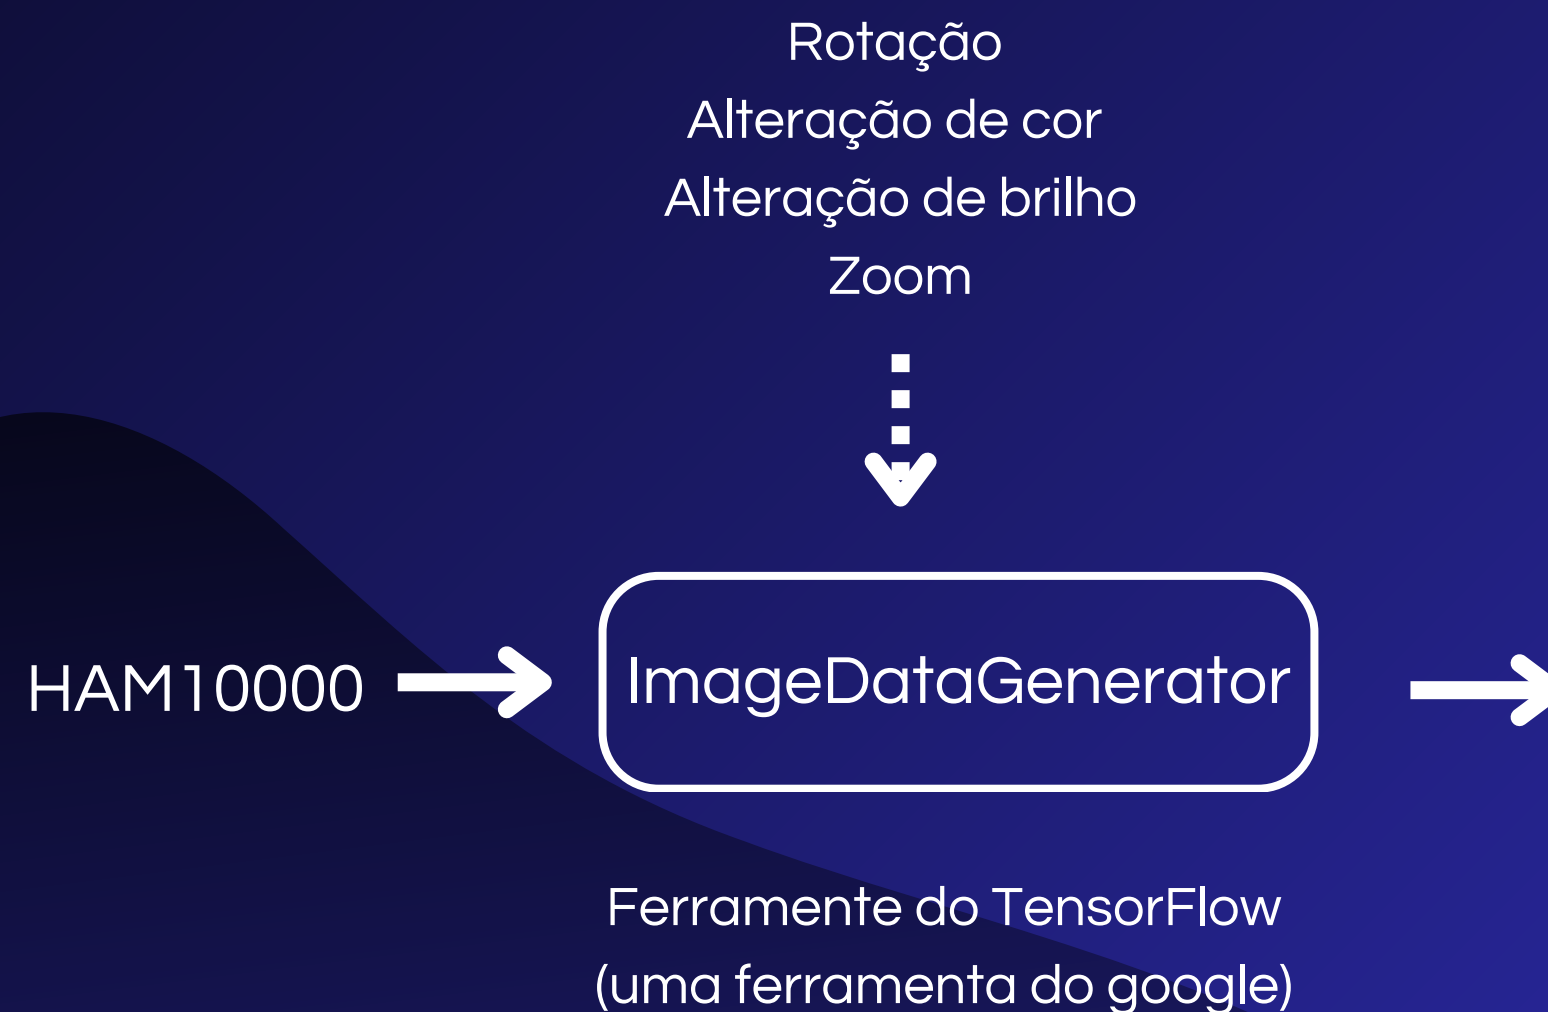
Desequilíbrio de dados

O banco de dados possui muito mais imagens de uma lesão de pele, do que em relação a melanoma

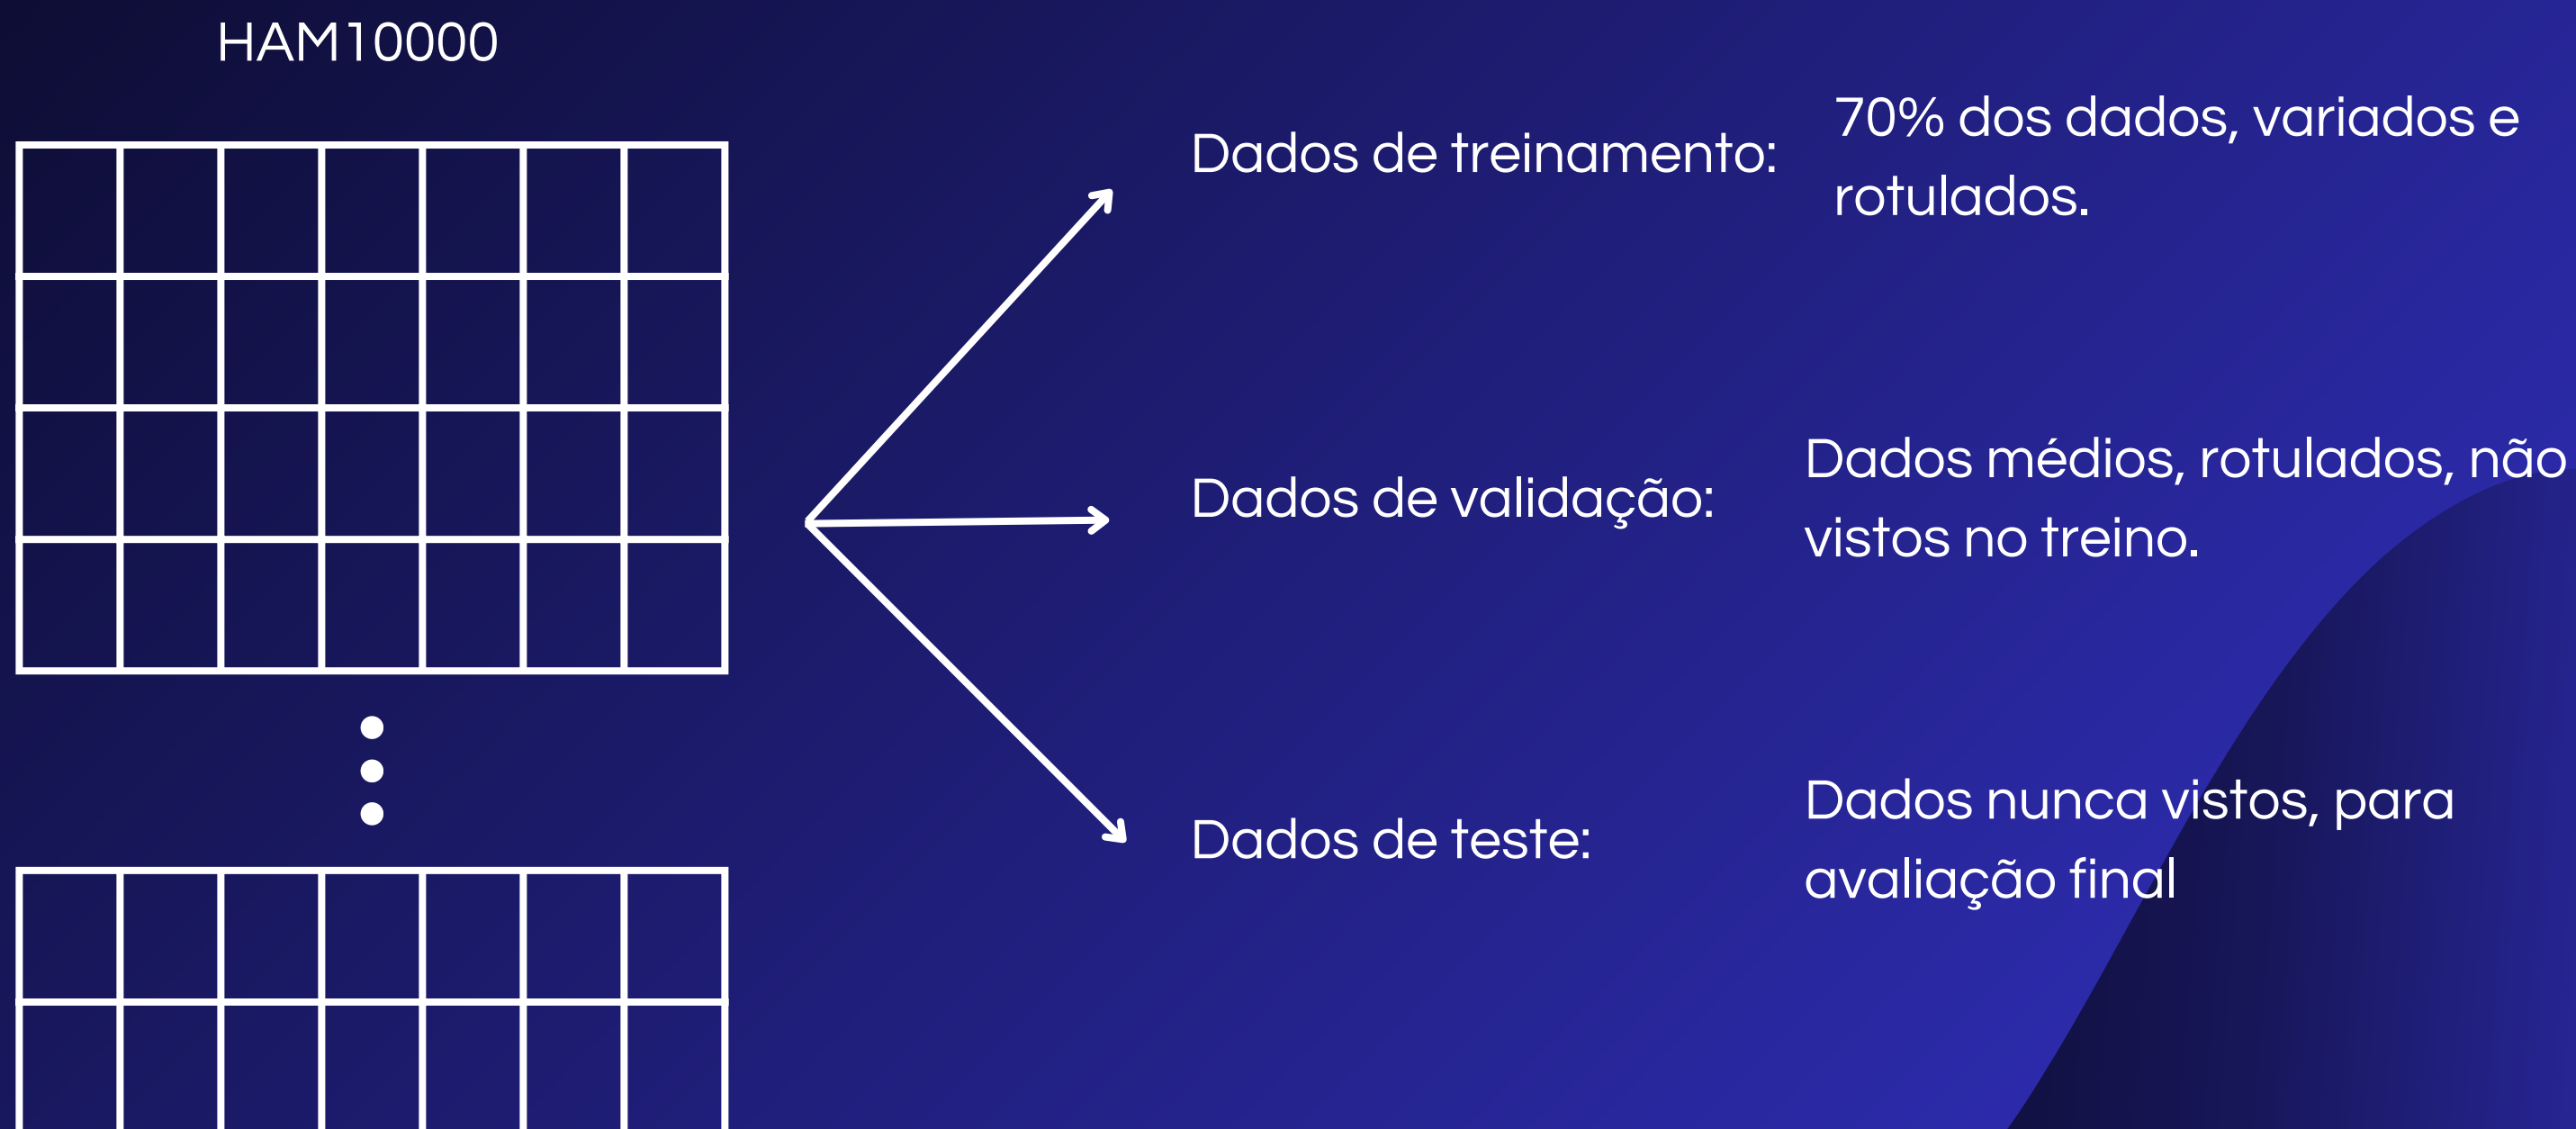
PROCESSO DE TREINAMENTO

Data augmentation

Para corrigir o desequilíbrio entre as classes de lesões no dataset, aplicamos data augmentation, gerando novas imagens com transformações como rotação, zoom e deslocamentos. Isso melhora a capacidade do modelo de generalizar as lesões, especialmente em cenários atípicos.



PROCESSO DE TREINAMENTO



PROCESSO DE TREINAMENTO



FERRAMENTAS

ferramentas de produção:

google colab




fonte do banco de dados:

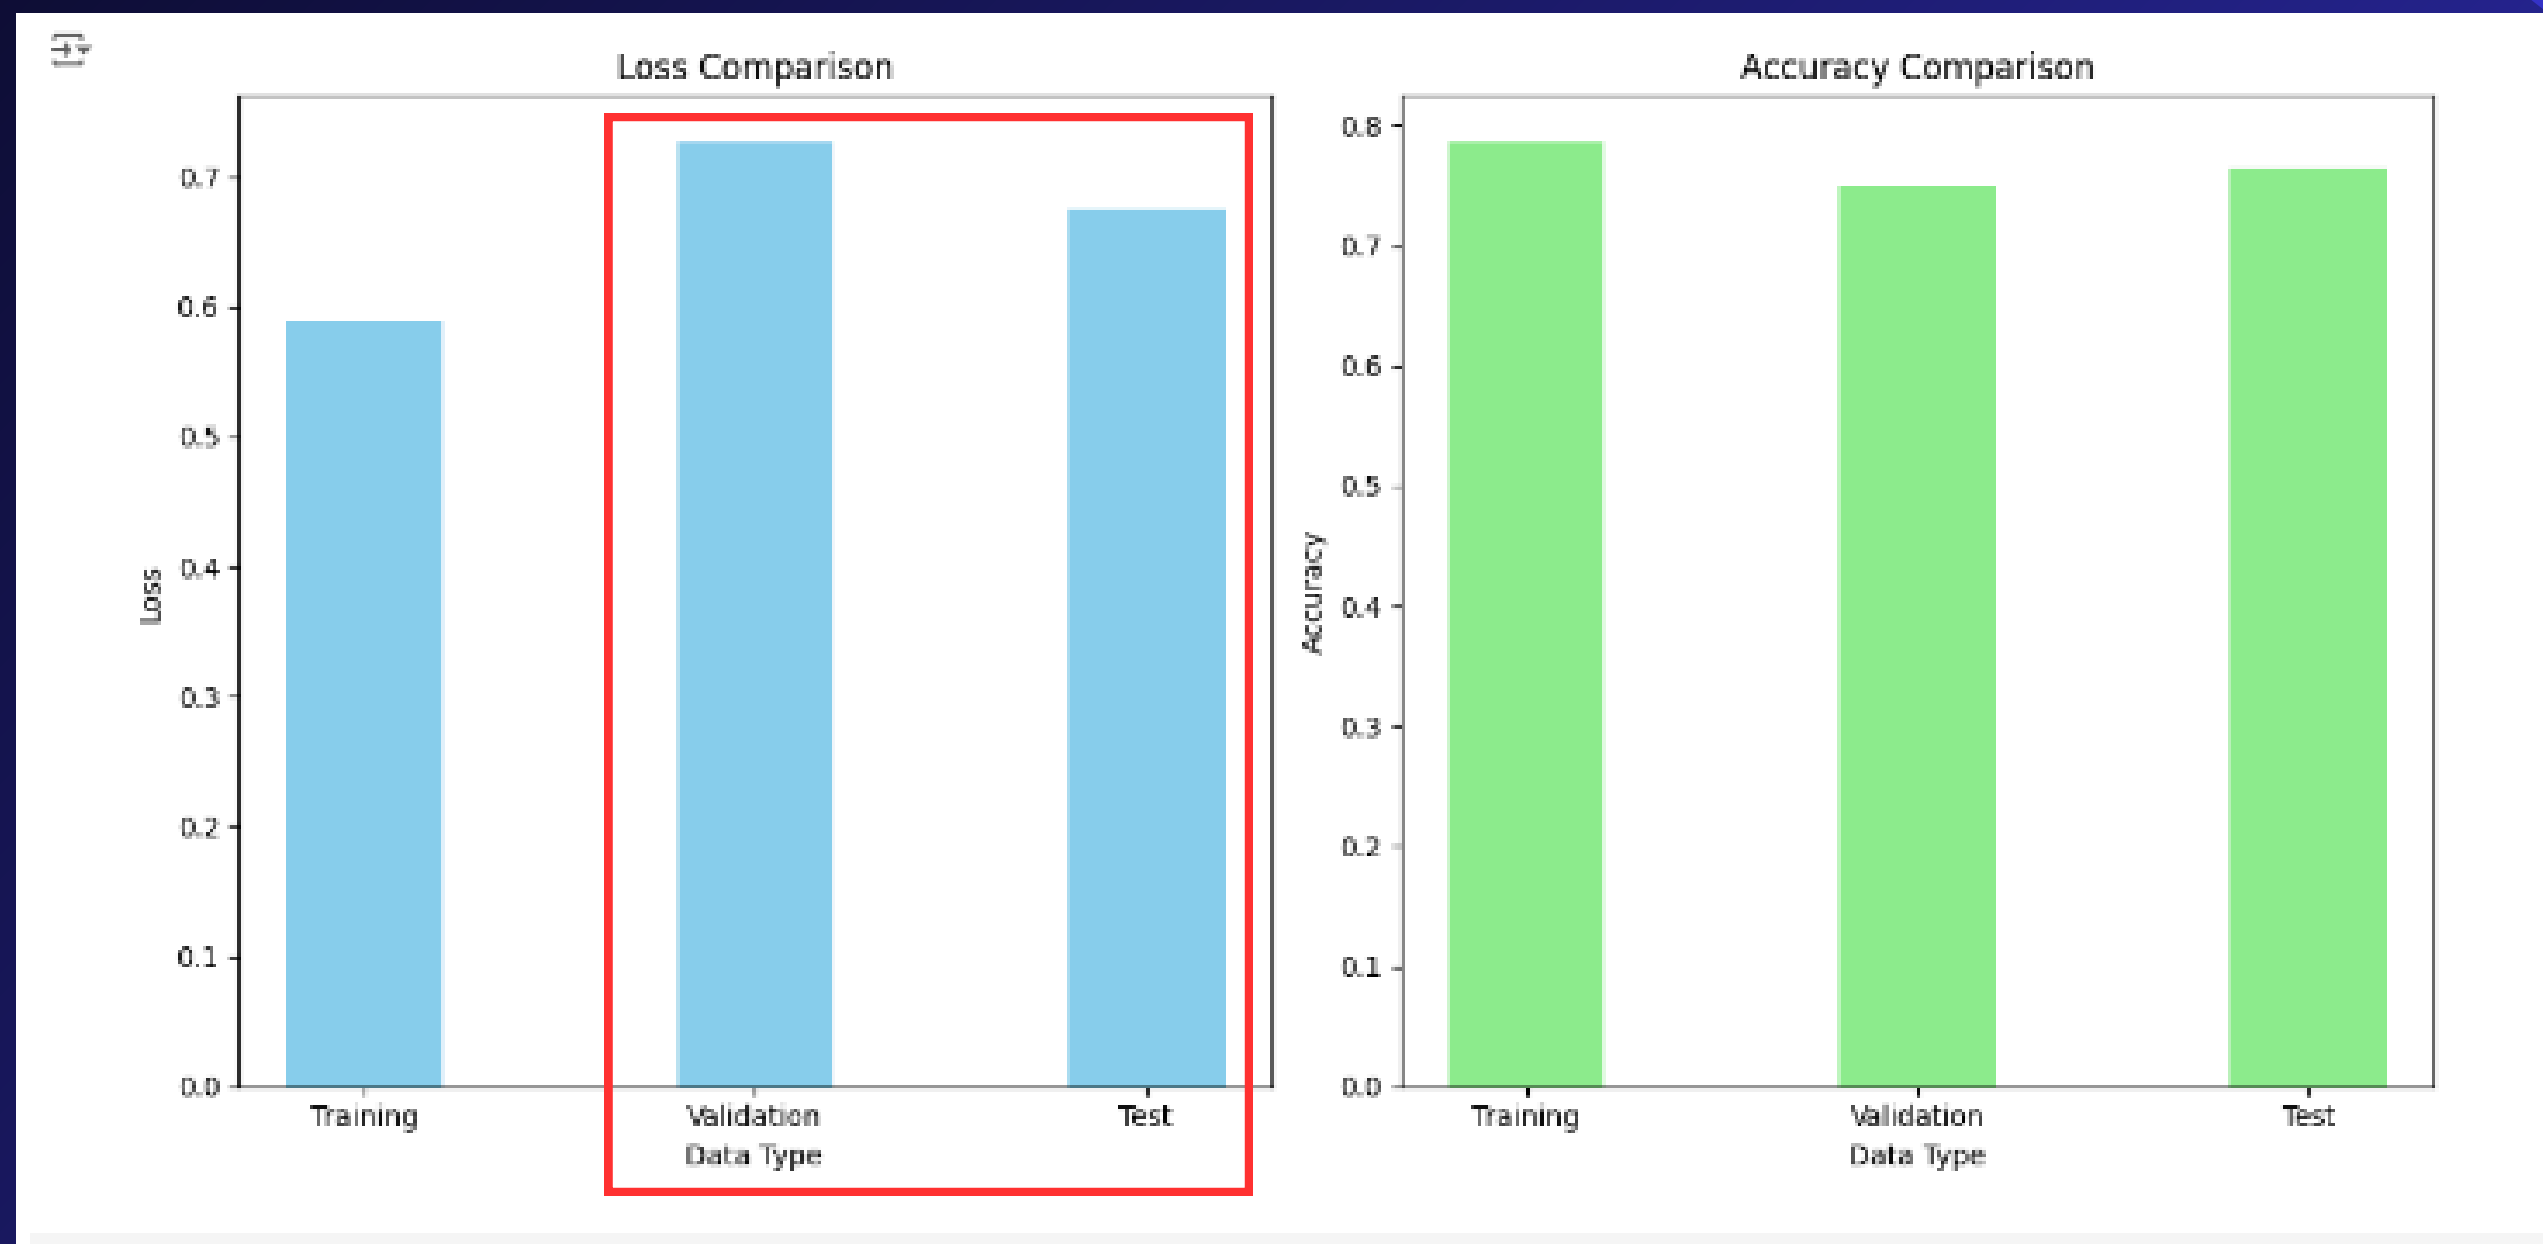
kaggle

RESULTADOS

O modelo alcançou uma acurácia de 75%, mas apresentou sinais de overfitting, com melhor desempenho nos dados de treinamento do que nos de validação. As tentativas de mitigar esse problema, como reduzir o número de épocas, não resultaram em melhorias significativas.



RESULTADOS



O modelo apresentou mais erros com dados não vistos durante o treinamento.

CONSIDERAÇÕES FINAIS




Desempenho do modelo

Apesar das modificações realizadas na arquitetura do VGG16, o modelo apresentou resultados abaixo do esperado, com acurácia de 75%, indicando dificuldade em generalizar e sinais de overfitting.



Limitações

A simplificação do modelo reduziu sua capacidade de capturar nuances nos dados médicos. Além disso, o banco de dados não reflete bem o contexto real, especialmente em um país como o Brasil.



Melhorias Futuras

Para melhorar o desempenho, será preciso ajustar a arquitetura, aplicar técnicas de regularização mais avançadas e equilibrar a complexidade do modelo com as limitações computacionais.

AGRADECIMENTOS

Gostaria de expressar meus sinceros agradecimentos ao meu coordenador, Prof. Dr. Ademar Takeo Akabane, e ao Prof. Fernando Soares de Aguiar Neto, por todo o apoio, orientação e incentivo durante o desenvolvimento deste trabalho. Suas contribuições foram fundamentais para o progresso e conclusão deste projeto.

BIBLIOGRAFIA

P. Tschandl, C. Rosendahl, and H. Kittler, "The ham10000 dataset, a large collection of multi-source derma- toscopic images of common pigmented skin lesions," Scientific data, vol. 5, no. 1, pp. 1–9, 2018.

Estimativa 2023 – incidência de câncer no brasil." <https://www.gov.br/inca/pt-br/>

https://www.tensorflow.org/api_docs/python/tf/keras/preprocessing/image/ImageDataGenerator

<https://colab.research.google.com/>

<https://www.objective.com.br/insights/deep-learning/>

<https://www.alura.com.br/artigos/lidando-com-desbalanceamento-dados#:~:text=involving%20information%20extraction.-,Oversampling,da%20classe%20com%20menor%20frequ%C3%Aancia.>

<https://medium.com/ensina-ai/tutorial-transfer-learning-3972cac5e9b5>

OBRIGADA!
